

PROJEKT BADAWCZY – część do zaliczenia przedmiotu metody probabilistyczne, Informatyka, semestr zimowy 2025/2026

Skład grup: 2–4 osoby.

Format: Raport R Markdown (.Rmd) + wygenerowany plik HTML lub PDF.

Źródło danych: Dowolny rzeczywisty zbiór danych (np. [Kaggle](#), [UCI Machine Learning Repository](#)).

Termin oddania: 2 tygodnie po zakończeniu ostatnich zajęć (**do 21 czerwca**)

1. Cel zadania

Celem projektu jest samodzielne przeprowadzenie mini-badania ilościowego – od przygotowania danych, poprzez analizy statystyczne, aż po interpretację wyników w formie wniosków.

Projekt ma charakter pracy grupowej (2–4 osoby). Każda grupa powinna jasno określić wkład poszczególnych członków zespołu.

Efektem końcowym jest:

- plik .Rmd
- wygenerowany raport (.html lub .pdf)

2. Dane do analizy

Dane powinny pochodzić z ogólnodostępnego źródła (np. Kaggle)
Zbiór danych musi zawierać minimum:

- 1000 obserwacji
- 10 zmiennych
- zmienne jakościowe oraz ilościowe

Tematyka może dotyczyć zakresu:

E-commerce, Medycyna/Biometria, Nieruchomości, Badania społeczne.

3. Zakres analizy

Część I: Metryczka i Dane

- **Podział prac:** Tabela z listą członków grupy i opisem, za co odpowiadała każda osoba (np. *Jan Kowalski: czyszczenie danych i regresja*, *Anna Nowak: analiza rozkładów i wnioskowanie*).
- **Opis zbioru:** Krótka informacja o pochodzeniu danych i definicja zmiennych (co mierzą, w jakich jednostkach).

Część II: Parametry i Rozkłady (Zmienne Jednowymiarowe)

- **Analiza opisowa:** Dla wybranej kluczowej zmiennej oblicz parametry położenia (średnia, mediana, odchylenie, zmienność) oraz kształtu (kurtoza, skośność).
- **Dopasowanie modelu:** Nałóż na histogram gęstości krzywą wybranego rozkładu teoretycznego (Normalny, Wykładniczy lub inny).
- **Wniosek:** Uzasadnij wybór modelu, odnosząc się do różnicy między średnią a medianą oraz wartości kurtozy.

Część III: Prawdopodobieństwo i Zmienne Dwuwymiarowe

- Zdefiniować co najmniej 2 zdarzenia, np.:
 - A: „klient dokonał zakupu”
 - B: „klient skorzystał z promocji”
- Obliczyć: $P(A)$, $P(B)$, $P(A | B)$
- sprawdzić niezależność zdarzeń

Część IV: Wnioskowanie Statystyczne (Estymacja i Hipotezy)

- **Przedziały ufności:** Wyznacz i zinterpretuj 95% przedział ufności dla średniej kluczowego parametru.
- **Testowanie hipotez:** Sformułuj i zweryfikuj co najmniej trzy hipotezy na zmiennej liczbowej (np. test t-Studenta dla dwóch grup czy ANOVA i ich nieparametryczne odpowiedniki) oraz dwie hipotezy na zmiennych jakościowych (np. test Chi-kwadrat dla niezależności cech). Pamiętaj o założeniach testów by je uwzględnić.
- **Ważne:** Podaj wartość p-value i zinterpretuj ją w odniesieniu do poziomu istotności $\alpha = 0.05$.

Część V: Relacje i Przewidywanie (Korelacja i Regresja)

- **Analiza korelacji:** Stwórz macierz korelacji (heatmap) dla zmiennych numerycznych oraz przeprowadź test statystyczny na istotność korelacji.
- **Regresja liniowa:** Zbuduj model przewidujący wybraną wartość. Wyświetl podsumowanie modelu (`summary()`).
- **Interpretacja:** Wyjaśnij znaczenie współczynnika R^2 oraz współczynników regresji beta czy wskazanie istotnych zmiennych modelu. Czy model jest istotny statystycznie?

4. Kryteria oceny

- **Poprawność metodologiczna:** Czy dobrano odpowiedni test do rodzaju danych? Czy interpretacja p-value jest słuszna?
 - **Jakość raportu:** Czy plik jest czytelny, wykresy mają opisy osi i legendy? Czy wnioski są sformułowane zrozumiałym językiem?
 - **Wykorzystanie R:** Poprawność kodu, komentarze, brak błędów przy generowaniu (knitting) pliku końcowego oraz zastosowanie pakietów data.table i ggplot2.
-

5. Forma oddania

Grupa oddaje:

A. Plik Rmd oraz na jego podstawie wygenerowany HTML bądź PDF

Zawierający wszystkie wykonane analizy, wykresy i tabele.

B. Opisy pod wykresami, tabelami i ogólny plan działania

Powinien zawierać:

1. Strona tytułowa

- temat projektu
- skład grupy
- **precyzyjny opis ról** (np. osoba A – pozyskanie danych i analiza danych; B – przygotowanie danych i analiza; C – analizy; D – raport / interpretacja)

2. Cel badania i opis danych

- problem badawczy
- sposób pozyskania danych (jeśli baza zewnętrzna – źródło i link do danych)

3. Przeprowadzane analizy

- każda analiza powinna zawierać:
 - krótki opis, po co została wykonana
 - **interpretację**
 - np. „Test t-Studenta wykazał istotną różnicę w poziomie stresu między kobietami a mężczyznami, $t(45)=2,45$, $p=0,018$.”

4. Podsumowanie i wnioski

6. Wymagania techniczne

- Wszystkie analizy **muszą być wykonane w R**
 - Nazwa pliku: *Grupa(3/4/5/6/7)_Indeks1 _Indeks2 _Indeks3 _Indeks4 _ProjektStatystyka*
-